

Lista zadań nr 3

Bazy Danych 2026

Zapytania koniunkcyjne to zapytania rrd zbudowane z formuł atomowych (np. $R(x, y)$) oraz koniunkcji i kwantyfikatorów egzystencjalnych. W ogólności formułami atomowymi mogą być również równości i nierówności między stałymi i zmiennymi (np. $x = 5$, $x \neq y$, $x < z$) ale na tej liście (o ile nie piszemy o tym wprost) pozwalamy wyłącznie na atomy relacyjne oraz nie pozwalamy na używanie stałych.

Rozważmy bazę danych reprezentującą pewien graf skierowany o krawędziach zapisanych w relacji $E(S, T)$. Niestety w naszych zapytaniach nie możemy używać relacji E . W zamian mamy dostęp do relacji $P_i(x, y)$ dla pewnych $i > 1$. Relacja $P_i(x, y)$ zawiera pary wierzchołków połączone ścieżką długości i , np. $P_2(x, z)$ mogłaby być zdefiniowana jako $(\exists y)E(x, y) \wedge E(y, z)$. Odpowiada to sytuacji, w której np. ze względów bezpieczeństwa dostęp do bazy danych mamy wyłącznie za pomocą zestawu perspektyw (widoków), a dostęp do oryginalnych relacji jest zablokowany.

Jeśli chcemy wyliczyć odpowiedzi na jakieś zapytanie ψ używające relacji E możemy spróbować zmodyfikować (przepisać) ψ tak aby zamiast E wykorzystać symbole dostępnych perspektyw. Np. jeśli mamy wyłącznie dostęp do perspektywy $P_2(x, y)$, a chcemy zapisać zapytanie $P_4(x, z) = (\exists y_1, y_2, y_3)E(x, y_1) \wedge E(y_1, y_2) \wedge E(y_2, y_3) \wedge E(y_3, z)$ możemy to zrobić tak: $P'_4(x, z) = (\exists y)P_2(x, y) \wedge P_2(y, z)$ (zauważ, że P'_4 też jest zapytaniem koniunkcyjnym i jest równoważne $P_4(x, y)$).

Na rozgrzewkę pokaż, jak przepisać zapytanie $P_7(x, y)$ używając wyłącznie perspektyw $P_2(x, y)$ i $P_3(x, y)$.

1. (1 pkt.) Pokaż, że nie istnieje takie zapytanie koniunkcyjne używające jako formuł atomowych wyłącznie perspektyw $P_3(x, y)$ i $P_4(x, y)$, które jest równoważne zapytaniu $P_5(x, y)$.
2. (1 pkt.) Napisz zapytanie rrd (dozwolone $\exists, \forall$ i wszystkie spójniki boolowskie), które korzysta wyłącznie z perspektyw $P_3(x, y)$ i $P_4(x, y)$ i jest równoważne zapytaniu $P_5(x, y)$.

Dziedziną bazy danych A , $\text{dom}(A)$, nazwiemy zbiór wszystkich elementów zawartych w krotkach w relacjach z A . Homomorfizm pomiędzy bazami danych A i B to funkcja $h : \text{dom}(A) \rightarrow \text{dom}(B)$ spełniająca warunek: dla każdego symbolu relacji R i każdej krotki $(a_1, \dots, a_n) \in \text{dom}(A)^n$ (gdzie n jest liczbą atrybutów R) zachodzi

$$A \models R(a_1, \dots, a_n) \implies B \models R(h(a_1), \dots, h(a_n))$$

3. (1 pkt)
 1. Pokaż, że istnieje graf G , taki, że dla dowolnego grafu G' istnieje homomorfizm z G' w G .
 2. Udowodnij lub podaj kontrprzykład na stwierdzenie: dla dowolnych grafów G_1 i G_2 następujące warunki są równoważne:
 - istnieją homomorfizmy $h_1 : G_1 \rightarrow G_2$ oraz $h_2 : G_2 \rightarrow G_1$ (mówimy, że takie grafy są *homomorficznie równoważne*)

- istnieje izomorfizm $f : G_1 \rightarrow G_2$.

4. (1 pkt) W tym zadaniu rozważamy grafy symetryczne tzn. takie, że jeśli istnieje krawędź z v do w to istnieje też krawędź z w do v . Pokaż, że każde dwa takie grafy będące cyklami o parzystej długości są homomorficznie równoważne.

5. (1 pkt.) Mówimy, że formuła rachunku zdań jest w postaci 3CNF, gdy jest w koniunkcyjnej postaci normalnej, a dodatkowo każda klauzula zawiera najwyżej 3 zmienne. Przykład formuły 3CNF: $(p \vee \neg q \vee r) \wedge (s \vee \neg r)$.

Rozważmy problem spełnialności formuł rachunku zdań zwany 3SAT: dla danej formuły w postaci 3CNF, rozstrzygnij czy istnieje wartościowanie ją spełniające.

Pokaż, że problem 3SAT można wyrazić jako problem istnienia homomorfizmu pomiędzy bazami danych, tzn. pokaż, że jeśli potrafisz rozwiązywać problem istnienia homomorfizmu to potrafisz także rozwiązywać problem 3SAT.

Twoja konstrukcja powinna działać w czasie wielomianowym.

6. (0.5 pkt.) Wiadomo, że problem 3SAT jest trudny obliczeniowo. Za wykazanie, że istnieje jakikolwiek wielomianowy algorytm rozwiązujący ten problem Clay Institute ufundował nagrodę w wysokości miliona dolarów. Problem ewaluacji zapytań koniunkcyjnych (czyli istnienia homomorfizmu) nie jest uznawany za szczególnie trudny, a silniki bazodanowe od wielu lat wydajnie wyliczają odpowiedzi na zapytania SQL. Tymczasem w zadaniu 5 tak naprawdę pokazaliśmy, że problem 3SAT jest łatwiejszy (lub równie trudny) jak problem istnienia homomorfizmu. Wyjaśnij dlaczego to nie jest paradoks (a rozwiązanie zadania 5 nie wystarczy aby otrzymać nagrodę).

W zadaniu o nullach z poprzedniej listy wymagaliśmy aby dla Q i D istniała taka baza ze zmiennymi Q_D (wynik Q na D), że

$$\text{rep}(Q_D) = Q(\text{rep}(D)) \quad (1)$$

Czyli inaczej mówiąc chcieliśmy móc wykonać zapytanie na bazie ze zmiennymi i móc zapisać jego wynik w postaci bazy ze zmiennymi. Niestety okazało się wtedy, że w ten sposób nie radzimy sobie nawet z zapytaniem z pojedynczą selekcją. Spróbujmy więc kilku innych podejść.

W zadaniach poniżej używamy standardowej logiki z dwiema wartościami logicznymi *true* i *false* oraz rozważamy zapytania algebry relacji bez grupowania. Dla uproszczenia w selekcjach warunki mogą być wyłącznie pojedynczym atomem z równością ($=$). Zakładamy, że D jest bazą ze zmiennymi i o schemacie z jedną relacją i traktujemy bazę D po prostu jako zbiór krotek w tej (jej jedynej) relacji.

Zdefiniujmy zbiór *pewnych odpowiedzi* na zapytanie Q na D następująco

$$\text{sure}(Q, D) = \bigcap \{Q(I) | I \in \text{rep}(D)\}$$

I przebiega wszystkie możliwe bazy ($=$ zbiory krotek) bez zmiennych, które są reprezentowane przez bazę ze zmiennymi D . Przekrój zbiorów odpowiedzi $Q(I)$ składa się z tych krotek, które występują w każdej możliwej odpowiedzi na zapytanie Q w D .

7. (0.5 pkt.) Zaproponuj algorytm obliczania dla danej bazy ze zmiennymi D zbioru

$$\bigcap \{I \mid I \in \text{rep}(D)\},$$

tzn. zbioru krotek obecnych w każdej bazie w $\text{rep}(D)$, zbiór ten oznaczmy $\text{sure}(D)$.
Z jakich krotek składa się ten zbiór?

8. (0.5 pkt.) Rozważmy następującą definicję wyniku zapytania

$$Q_D = \text{sure}(Q, D) \quad (2)$$

Zauważ, że to nie jest dobra definicja. Skonstruuj relację D i dwa zapytania Q' i Q'' takie, że obliczenie wyniku zapytania $Q'' \circ Q'$ będącego złożeniem Q'' i Q' na D zwraca inną odpowiedź niż obliczenie Q'' na $\text{sure}(Q', D)$ czyli na bazie będącej wynikiem obliczenia Q' na D . Zapisując formalnie:

$$\text{sure}(Q'' \circ Q', D) \neq \text{sure}(Q'', \text{sure}(Q', D))$$

W naszym przypadku złożenie zapytania Q'' i Q' to po prostu wyrażenie algebry relacji Q'' , w którym wszystkie odwołania do bazy wejściowej zastąpiono wyrażeniem Q' . Np. złożeniem zapytań $\sigma_{B=C}(D)$ i $\sigma_{A>7}(D)$ jest wyrażenie $\sigma_{B=C}(\sigma_{A>7}(D))$.

Hint: szukaj prostego triku - o czym zapominamy biorąc jako wynik pośredni $\text{sure}(Q', D)$?

Skonstruuj przykład tak, aby Q_D było puste, a wynik złożenia Q'' i Q' na D nie.

Wniosek: wynik Q_D trzeba zdefiniować tak aby zawierał więcej informacji niż $\text{sure}(Q, D)$.

9. (1 pkt., nie wlicza się do maksimum) Przetestujmy więc kolejne podejście. Tym razem na Q_D zamiast warunku (1) nałożmy taki:

$$\text{sure}(Q_D) = \text{sure}(Q, D) \quad (3)$$

Czyli wymagamy aby zbiór krotek w przekroju wszystkich baz z $\text{rep}(Q_D)$ był równy $\text{sure}(Q, D)$. Różnica w stosunku do poprzedniego podpunktu jest teraz taka, że nasz wynik Q_D może zawierać krotki ze zmiennymi.

Pokaż jak zdefiniować selekcję oraz projekcję na bazach z zmiennymi tak aby dla dowolnego zapytania Q zbudowanego z selekcji i projekcji oraz dowolnej bazy ze zmiennymi D wynik Q_D istniał, spełniał warunek (3), a dodatkowo zapytania można było składać.