

MCTS, gry jednoturowe i markowskie procesy decyzyjne

Paweł Rychlikowski

Instytut Informatyki UWr

27 kwietnia 2026

Jednoręki bandyta i wieloręcy bandyci. Przypomnienie



Źródło: Wikipedia

- Mamy wiele tego typu maszyn.
- Możemy zapomnieć o wzorkach, maszyny po prostu generują wypłatę, zgodnie z nieznanym rozkładem.
- Bardzo wyraźnie widać **dylemat eksploracja vs eksploatacja**.

Jednoręki bandyta i wieloręcy bandyci. Przypomnienie



Źródło: Wikipedia

- Mamy wiele tego typu maszyn.
- Możemy zapomnieć o wzorkach, maszyny po prostu generują wypłatę, zgodnie z nieznanym rozkładem.
- Bardzo wyraźnie widać **dylemat eksploracja vs eksploatacja**.

- Strategia ϵ -**zachłanna**: rzucamy monetą. Z $p = \epsilon$ wykonujemy ruch losową rączką, z $p = 1 - \epsilon$ – wykonujemy ruch rączką, która ma najlepszy **średni** wynik do tej pory.
- Na kolejnym slajdzie trochę lepszy wariant balansowania między eksploracją a eksploatacją

Upper Confidence Bound

- Wybieramy akcję a (bandytę) maksymalizującą:

$$Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}}$$

gdzie: Q_t to uśredniona wartość akcji do momentu t , N_t – ile razy dana akcja była wybierana (do momentu t)

- Zwróćmy uwagę, że jak akcja nie jest wybierana, to prawy składnik powoli rośnie. Akcja wybierana natomiast traci „premię eksploracyjną”, na początku w szybkim tempie (wzrost mianownika).

Uwaga

Bardzo powszechnie używana strategia! (np. w AlphaGo)


Monte Carlo Tree Search

Algorytm odpowiedzialny za przełom w:

- a. W grze w Go
- b. W General Game Playing

Główne idee

- 1. Oceniamy sytuację wykonując symulowane rozgrywki.
- 2. Budujemy drzewo gry (na początku składające się z jednego węzła – stanu przed ruchem komputera)
- 3. Dla każdego węzła utrzymujemy statystyki, mówiące o tym, kto częściej wygrywał gry rozpoczynające się w tym węźle (pamiętamy też listę możliwych ruchów, ewentualnie wraz ze stanami)
- 4. Intuicja: przypominamy sobie drzewo trie dla książki otworzyć powstałej z wielu (milionów) gier



Opcje

- Jeżeli wejdziemy do węzła, w którym nie wszystkie dzieci są rozwinięte, to możemy wymusić, że brany jest pod uwagę nieuwzględniony ruch.
- Możemy korzystać z jakiejś heurystyki oceniającej ruchy i brać tylko obiecujące ruchy

1. **Selection**: wybór węzła do którego wejdziemy (być może wcześniej go tworząc). Stosujemy UCB
2. **Expansion**: rozwinięcie drzewa (dodanie węzła)
3. **Simulation**: symulowana rozgrywka (zgodnie z jakąś polityką), zaczynające się od wybranego węzła
4. **Backup**: uaktualnienie statystyk dla rozwiniętego węzła i jego przodków

Uwaga

Korzystność ruchu oceniamy z punktu widzenia aktualnego gracza.

- Możemy grać nie do końca, wówczas jednak potrzebujemy jakiejś funkcji heurystycznej oceniającej sytuację na planszy
- Rozgrywka nie musi być prostym losowaniem, p-stwo ruchu może zależeć od jego (**szybkiej!**) oceny (to powinno być coś bardzo szybkiego, niekoniecznie funkcja z podpunktu wyżej)

Uwaga

Im więcej obrotów pętli, tym lepsza gra – precyzyjne sterowanie trudnością i czasem działania.

Wybór ruchu

- Naturalny wybór: ruch do najlepiej ocenianej sytuacji
- Inna opcja: ruch do sytuacji, w której byliśmy najwięcej razy

- W pewnym sensie opcje są podobne: UCB też raczej wybiera dobre ruchy (eksploatacja!)
- Wybierając częstą sytuację, uwzględniamy wiarygodność szacunków
- Pojedyncza bardzo korzystna partia zmienia stosunkowo niewiele

Jeszcze o rozgrywce i wyborze węzła w MCTS

- Ciekawa idea: **all-moves-as-first**: w danej sytuacji na planszy szacujemy jakość ruchów widzianych (w symulacjach, w $\alpha\beta$ -search też by się dało to zastosować) niezależnie od tego, w którym momencie się zdarzyły
- Motywacja: w tej sytuacji **zawsze** jak ruszę hetmanem na B5 to wygrywam
- Możemy liczyć wartość ruchu jako średni wynik rozgrywki, w której ten ruch był wykonany.
- **Uwaga**: nie $Q(s, a)$, ale $Q(a)$! (ta wartość nie zależy od konkretnego momentu, w którym ruch został wykonany)

Więcej szczegółów w pracy S.Gelly, D.Silver, *Monte-Carlo Tree Search and Rapid Action Value Estimation in Computer Go*

- Nie tylko do gier!
- Można stosować do *poważnych* zadań, związanych z przeszukiwaniem (bez oponenta)
 - Na przykład do rozwiązywania więzów (pewnie szczegóły na ćwiczeniach)

Zagadka: co robią robotnik i kołchoźnica?






Gry z jedną turą

- Powiemy sobie trochę o grach z jedną turą
- Ale takich, w których gracze podejmują swoje decyzje jednocześnie

Rozważamy gry z **sumą zerową**.

Papier, nożyce, kamień



Źródło: Wikipedia

Macierz wypłat

Grę definiuje **macierz wypłat**. Przykładowo poniżej dla P-N-K

Max/Min	Papier	Nożyce	Kamień
Papier	0	-1	+1
Nożyce	+1	0	-1
Kamień	-1	+1	0

- Czysta strategia: zawsze akcja a
- Mieszana strategia: rozkład prawdopodobieństwa na akcjach

- **Oczywisty fakt:** każdą strategię stałą można pokonać (też stałą strategią)
- **Fakt 1:** każdą strategię mieszaną można (prawie) pokonać za pomocą strategii stałej:
Mój przeciwnik gra losowo, ale z przewagą kamienia – zatem ja daję **zawsze papier**
- **Fakt 2:** Optymalna strategia jest mieszana (w tej grze każde z $p = \frac{1}{3}$)
- **Fakt 3:** Znajomość optymalnej strategii mieszanej gracza A, nie daje żadnej przewagi graczowi B (i odwrotnie)

- W **prawdziwym** P-N-K dochodzi kilka innych aspektów:
 - Grają ludzie, którzy nie potrafią realizować losowości,
Który człowiek (nie dysponując kostką do gry), przegrawszy 3 razy z rzędu jako papier pokaże papier?
 - za to wysyłają swoimi ciałami różne informacje, które można analizować
- Zatem ma sens organizowanie zawodów w PNK
- Sens miałyby również zawody ludzko-komputerowe, realizowane on-line (agent musiałby zgadnąć, czy gra z człowiekiem, czy z maszyną i czy opłaca się próbować zgadnąć model losowania używany przez człowieka)

Gra w zgadywanie (Morra 2)

- Mamy dwóch graczy:

Ⓐ) Zgadywacz

Ⓑ) Zmyłek

którzy na sygnał pokazują 1 lub 2 palce.

- Jeżeli Zgadywacz nie zgadnie (pokazał coś innego niż Zmyłek), daje Zmyłkowi 3 dolary.
- Jeżeli Zgadywacz zgadnie, to dostaje od Zmyłka:
 - jak pokazali 1 palec, to 2 dolary
 - jak pokazali 2 palce, to 4 dolary

Pytanie

Jak grać w tę grę? (prośba o podanie wstępnych intuicji)

Definicja

Taką grę zadajemy za pomocą **macierzy wypłat**, w której $V_{a,b}$ jest wynikiem gry z punktu widzenia pierwszego gracza.

Nasza gra:

Zg/Zm	1 palec	2 palce
1 palec	2	-3
2 palce	-3	4

- Jak **Zmyłek** będzie grał cały czas to samo, to **Zgadywacz** wygra każdą turę (i odwrotnie)
- Muszą zatem stosować strategie mieszane, ale jakie?

Definicja

Wartość gry dla dwóch strategii graczy jest równa:

$$V(\pi_A, \pi_B) = \sum_{a,b} \pi_A(a) \pi_B(b) V(a, b)$$

Przykładowo: Zgadywacz zawsze zgaduje 1, Zmyłek wybiera akcję losowo z prawdopodobieństwem **0.5**.

Wynik: $-\frac{1}{2}$ (tak samo często zyskuje 2 jak traci 3 dolary)

Strategia mieszana vs czysta

Uwaga

Jeżeli gracz A zapowie, że będzie grał strategią mieszaną (i ją poda), wówczas gracz B może grać strategią czystą (i osiągnie optymalny wynik).

Dlaczego?

Odpowiedź

- Możemy dla każdej akcji policzyć wartość oczekiwaną wypłaty
- i wybrać (dowolną) najlepszą akcję
- (Jeżeli takich akcji jest więcej, wówczas można też dowolnie losować między nimi)

Gra w zgadywanie (Morra 2). Przypomnienie

- Mamy dwóch graczy:

Ⓐ) Zgadywacz

Ⓑ) Zmyłek


którzy na sygnał pokazują 1 lub 2 palce.

- Jeżeli Zgadywacz nie zgadnie (pokazał coś innego niż Zmyłek), daje Zmyłkowi 3 dolary.
- Jeżeli Zgadywacz zgadnie, to dostaje od Zmyłka:
 - jak pokazali 1 palec, to 2 dolary
 - jak pokazali 2 palce, to 4 dolary

Znalezienie optymalnej strategii

Zaczyna gracz B – Zmyłek.


Wybiera strategię mieszaną z parametrem p




Wartość takiej gry to

$$\min_{p \in [0,1]} (\max(5p - 3, -7p + 4))$$

Optymalna strategia. Wykresy



Optymalna strategia. Wykresy



Znalezienie optymalnej strategii (2)

- W powyższej grze, Zmyłek osiągnie najlepszy wynik, gdy przyjmie $p = \frac{7}{12}$, wynik ten to $-\frac{1}{12}$
- Ok, on zaczynał, miał trudniej – a gdyby zaczynał Zgadywacz? I podał swoją strategię mieszaną?

Wynik gry

Wynik jest dokładnie taki sam, czyli $-\frac{1}{12}$!

Twierdzenie, von Neuman, 1928

Dla każdej jednoczesnej gry dwuosobowej o sumie zerowej ze skończoną liczbą akcji mamy:

$$\max_{\pi_A} \min_{\pi_B} V(\pi_A, \pi_B) = \min_{\pi_B} \max_{\pi_A} V(\pi_A, \pi_B)$$

dla dowolnych mieszanych polityk π_A, π_B .

- Można ujawnić swoją politykę optymalną!
- **Dowód:** pomijamy, programowanie liniowe, przedmiot J.B.
- Algorytm: programowanie liniowe

- Można o grze wieloturowej myśleć jako o grze jednoturowej
- Gracze na sygnał kładą przed sobą opis strategii (program)

Uwaga

Optymalną strategią jest MiniMax (ExpectMiniMax w grach losowych). Ale wiedząc o strategii gracza różnej od optymalnej możemy oczywiście ugrać więcej.

- Gry o sumie niezerowej, w których dochodzi możliwość kooperacji.
- Punkt równowagi Nasha (jest zawsze para strategii, że żaden gracz nie chce jej zmienić, wiedząc, że ten drugi nie zmienia).
Również dla gier o sumie niezerowej!
- Agent musi zdecydować, czy ma być miły dla innego agenta (i budować reputację przy wielu rozgrywkach, słynny **dylemat więźnia**).

Procesy decyzyjne Markowa



Procesy decyzyjne Markowa (MDP)

- Coś pomiędzy grami a zwykłym zadaniem przeszukiwania
- (zwłaszcza jeżeli przypomnimy sobie gry z węzłami losowymi)
- a jednocześnie krok w stronę uczenia ze wzmocnieniem

MDP a przeszukiwanie

Standardowe przeszukiwanie

Znamy mechanikę świata i wiemy, że **akcja** w **stanie** da nam **konkretny rezultat (inny stan)**.

MDP

Znamy mechanikę świata i wiemy, że **akcja** w **stanie** da nam **pewien rozkład prawdopodobieństwa na następnych stanach**.

Nie wiemy, co dokładnie się stanie, ale wiemy co **może** się stać i z jakim prawdopodobieństwem.

- Przyszłość zależy od ostatniego stanu.
- Nie zależy od historii...
- Chyba, że jej fragment (o długości N) uznamy za część stanu.

Ważna uwaga

Zakładamy **skończoną** liczbę stanów

Uwaga na wulkany (1)

- Dobrze omawia się MDP na prostych światach na prostokątnej kratce.
- I od takich modeli zaczniemy.

Generalnie myślimy na początku o przestrzeni stanów na tyle małej, że nie będzie kłopotów z pamiętaniem różnych wartości dla **każdego stanu**.

Uwaga na wulkany (2)

Volcano crossing



		-50	20
		-50	
2			

Mechanika świata wulkanów

		-50	20
		-50	
2			

- Możliwe 4 akcje (UDLR)
- W normalnym przypadku efekt oczywisty (próba wyjścia poza planszę oznacza pozostanie na polu)
- Z prawdopodobieństwem p możemy się poślizgnąć, wówczas poruszamy się w losowym kierunku.
- Dojście do pola z liczbą kończy grę (i odpowiednią dostajemy wypłatę).

Inny przykład. Gra w kości

Uwaga

Nagroda może być przydzielana w sposób ciągły, nie tylko w stanie końcowym.


- Mamy dwie opcje: **pozostanie** albo **rezygnacja**.
- **rezygnacja** oznacza wypłatę **10\$**
- **pozostanie** to wypłata **4\$** po której rzucamy kostką.
- Interpretacja wyniku:
 - 1,2 – koniec gry
 - 3,4,5,6 – gramy dalej

Pytanie

Ile mamy stanów? Odpowiedź: 2

- 1 stan z decyzją, dwie **polityki** (czyli sensowne sposoby gry) (schemat na kolejnym slajdzie).
- Możemy policzyć oczekiwaną wartość dla każdej:
 - **rezygnacja** – 10
 - **pozostanie** – (na kolejnym slajdzie)

Schemat stanów



Oceniamy strategię **pozostanie**, czyli przedłużania gry.

- Oznaczamy przez V wartość tej polityki (czyli ile średnio zarobimy, jak nie będziemy nigdy rezygnować z gry)
- V spełnia równanie:

$$V = \frac{2}{3} \times (4 + V) + \frac{1}{3} \times 4 = 4 + \frac{2}{3} \times V$$

- Czyli $V = 12$, zatem opłaca się pozostawać w grze (bo $12 \geq 10$)

Uwaga

Tu była tylko jedna decyzja: 10 czy V , ale podobnie można rozwiązywać również (dużo) bardziej złożone MDP: rozwiązując równania i znajdując wartości stanów.