

Uczenie (różne warianty)


Paweł Rychlikowski

Instytut Informatyki UWr

28 maja 2026


Gradient. Przypomnienie

Wizualizacja gradientu w dla funkcji $\mathcal{R}^2 \rightarrow \mathcal{R}$



Gradient. Przypomnienie


Wizualizacja gradientu w dla funkcji $\mathcal{R}^2 \rightarrow \mathcal{R}$



- Gdy szukamy minimum funkcji, poruszamy się w kierunku przeciwnym do gradientu

Gradient. Przypomnienie

Wizualizacja gradientu w dla funkcji $\mathcal{R}^2 \rightarrow \mathcal{R}$



- Gdy szukamy minimum funkcji, poruszamy się w kierunku przeciwnym do gradientu
- Krok optymalizacji:
$$x = x - \alpha \frac{\partial f(x,y)}{\partial x}$$
$$y = y - \alpha \frac{\partial f(x,y)}{\partial y}$$
gdzie α jest małą liczbą dodatnią

Przypomnienie:

- 1 Chcemy napisać funkcję **kary** za złe rozwiązanie
- 2 Zmiennymi, które przekształcamy będą **surowe** wartości, ujemne oznaczające 0, dodatnie oznaczające 1

Przypomnienie:

- 1 Chcemy napisać funkcję **kary** za złe rozwiązanie
- 2 Zmiennymi, które przekształcamy będą **surowe** wartości, ujemne oznaczające 0, dodatnie oznaczające 1

Wracamy do burz

Przypomnienie:

- ❶ Chcemy napisać funkcję **kary** za złe rozwiązanie
- ❷ Zmiennymi, które przekształcamy będą **surowe** wartości, ujemne oznaczające 0, dodatnie oznaczające 1

Wracamy do omówienia kodu

Coś więcej niż gradient: RMS-Prop

The key formula for RMSprop is:

$$S_{dx} = \beta \times S_{dx} + (1 - \beta) \times (\nabla J)^2$$

$$\theta = \theta - \frac{\alpha}{\sqrt{S_{dx} + \epsilon}} \times \nabla J$$

Where:

- S_{dx} is a running average of the squared gradient for parameter θ .
- β is a decay factor, typically set close to 1 (e.g., 0.9).
- ∇J is the gradient of the loss function J with respect to parameter θ .
- α is the global learning rate.
- ϵ is a small constant to prevent division by zero (e.g., $1e - 10$).

Coś więcej niż gradient: Adam

For each Parameter w^j

(j subscript dropped for clarity)

$$\nu_t = \beta_1 * \nu_{t-1} - (1 - \beta_1) * g_t$$

$$s_t = \beta_2 * s_{t-1} - (1 - \beta_2) * g_t^2$$

$$\Delta\omega_t = -\eta \frac{\nu_t}{\sqrt{s_t + \epsilon}} * g_t$$

$$\omega_{t+1} = \omega_t + \Delta\omega_t$$

η : Initial Learning rate

g_t : Gradient at time t along ω^j

ν_t : Exponential Average of gradients along ω_j

s_t : Exponential Average of squares of gradients along ω_j

β_1, β_2 : Hyperparameters

Gradient i sieci neuronowe. Przypomnienie

Zadanie

Danymi jest ciąg (x_i, y_i) opisujący porządane zachowanie sieci S oraz architektura tejże sieci (liczba warstw, ich wymiary, funkcja/funkcje σ).

Gradient i sieci neuronowe. Przypomnienie

Zadanie

Danymi jest ciąg (x_i, y_i) opisujący porządane zachowanie sieci S oraz architektura tejże sieci (liczba warstw, ich wymiary, funkcja/funkcje σ). Chcemy tak dobrać parametry (W_k oraz b_k) żeby dla każdego i

$$S(x_i) \approx y_i$$

Gradient i sieci neuronowe. Przypomnienie

Zadanie

Danymi jest ciąg (x_i, y_i) opisujący porządane zachowanie sieci S oraz architektura tejże sieci (liczba warstw, ich wymiary, funkcja/funkcje σ). Chcemy tak dobrać parametry (W_k oraz b_k) żeby dla każdego i

$$S(x_i) \approx y_i$$

Funkcja kosztu

Powyższe zadanie formalizujemy jako zadanie znalezienia takich parametrów, że **koszt** błędów jest jak najmniejszy. Przykładowo, jeżeli wyjściem jest liczba, to możemy wybrać:

$$\text{Loss}(\theta) = \sum_i^n (S_\theta(x_i) - y_i)^2$$

Gradient i sieci neuronowe. Przypomnienie

Zadanie

Danymi jest ciąg (x_i, y_i) opisujący porządane zachowanie sieci S oraz architektura tejże sieci (liczba warstw, ich wymiary, funkcja/funkcje σ). Chcemy tak dobrać parametry (W_k oraz b_k) żeby dla każdego i


$$S(x_i) \approx y_i$$

Funkcja kosztu


Powyższe zadanie formalizujemy jako zadanie znalezienia takich parametrów, że **koszt** błędów jest jak najmniejszy. Przykładowo, jeżeli wyjściem jest liczba, to możemy wybrać:

$$\text{Loss}(\theta) = \sum_i^n (S_\theta(x_i) - y_i)^2$$


Minimalizujemy funkcję kosztu za pomocą gradientu po wszystkich parametrach θ



- Łatwo zwizualizować minimalizację gradientową dla dwóch parametrów



- Łatwo zwizualizować minimalizację gradientową dla dwóch parametrów
- Dla burz mieliśmy kilkadziesiąt parametrów



- Łatwo zwizualizować minimalizację gradientową dla dwóch parametrów
- Dla burz mieliśmy kilkadziesiąt parametrów
- W naprawdę dużych modelach optymalizujemy bilion lub więcej parametrów

$$\text{Loss}(\theta) = \sum_i^n (S_\theta(x_i) - y_i)^2$$

- Obliczenie gradientu wymaga przejścia przez cały zbiór uczący

$$\text{Loss}(\theta) = \sum_i^n (S_{\theta}(x_i) - y_i)^2$$

- Obliczenie gradientu wymaga przejścia przez cały zbiór uczący
- Ale pamiętamy: pochodna sumy, to suma pochodnych

$$\text{Loss}(\theta) = \sum_i^n (S_{\theta}(x_i) - y_i)^2$$

- Obliczenie gradientu wymaga przejścia przez cały zbiór uczący
- Ale pamiętamy: pochodna sumy, to suma pochodnych

Stochastic Gradient Descent

Obliczamy nie cały gradient, tylko jego składnik, związany z jednym egzemplarzem danych uczących i jego dodajemy (przemnożonego przez stałą)

$$\text{Loss}(\theta) = \sum_i^n (S_{\theta}(x_i) - y_i)^2$$

- Obliczenie gradientu wymaga przejścia przez cały zbiór uczący
- Ale pamiętamy: pochodna sumy, to suma pochodnych

Stochastic Gradient Descent

Obliczamy nie cały gradient, tylko jego składnik, związany z jednym egzemplarzem danych uczących i jego dodajemy (przemnożonego przez stałą)

Pytanie

Jakie to daje korzyści?

- Funkcja obliczająca wartość sieci zmienia się częściej (jest coraz lepsza), a zatem gradienty są coraz dokładniejsze

- Funkcja obliczająca wartość sieci zmienia się częściej (jest coraz lepsza), a zatem gradienty są coraz dokładniejsze
- Tak btw: często bierzemy nie jeden egzemplarz danych uczących, lecz kilka, i nazywamy to **wsadem** (batch)

- Funkcja obliczająca wartość sieci zmienia się częściej (jest coraz lepsza), a zatem gradienty są coraz dokładniejsze
- Tak btw: często bierzemy nie jeden egzemplarz danych uczących, lecz kilka, i nazywamy to **wsadem** (batch)
- Karta graficzna jest w stanie w znacznym stopniu zrównoleglić obliczenia dla całego wsadu

Gradient dla funkcji liniowej

Wzór

Pochodna po w_i (dla liniowej funkcji f_w)

$$\frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} 2 \cdot (f_w(x) - y) \cdot w_i \phi_i(x)$$

- W tłumaczeniu na Reversi:

Gradient dla funkcji liniowej

Wzór

Pochodna po w_i (dla liniowej funkcji f_w)

$$\frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} 2 \cdot (f_w(x) - y) \cdot w_i \phi_i(x)$$

- W tłumaczeniu na Reversi:
 - x to sytuacja na planszy, y to wartość sytuacji

Gradient dla funkcji liniowej

Wzór

Pochodna po w_i (dla liniowej funkcji f_w)

$$\frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} 2 \cdot (f_w(x) - y) \cdot w_i \phi_i(x)$$

- W tłumaczeniu na Reversi:
 - x to sytuacja na planszy, y to wartość sytuacji
 - $\phi_i(x)$ to pewien aspekt sytuacji na planszy, na przykład bilans punktów narożnych

Gradient dla funkcji liniowej

Wzór

Pochodna po w_i (dla liniowej funkcji f_w)

$$\frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} 2 \cdot (f_w(x) - y) \cdot w_i \phi_i(x)$$

- W tłumaczeniu na Reversi:
 - x to sytuacja na planszy, y to wartość sytuacji
 - $\phi_i(x)$ to pewien aspekt sytuacji na planszy, na przykład bilans punktów narożnych
 - w_i to waga tego parametru,

Gradient dla funkcji liniowej

Wzór

Pochodna po w_i (dla liniowej funkcji f_w)

$$\frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} 2 \cdot (f_w(x) - y) \cdot w_i \phi_i(x)$$

- W tłumaczeniu na Reversi:
 - x to sytuacja na planszy, y to wartość sytuacji
 - $\phi_i(x)$ to pewien aspekt sytuacji na planszy, na przykład bilans punktów narożnych
 - w_i to waga tego parametru,
 - $f_w(x)$ to wartość funkcji heurystycznej dla planszy x

Gradient dla funkcji liniowej

Wzór

Pochodna po w_i (dla liniowej funkcji f_w)

$$\frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} 2 \cdot (f_w(x) - y) \cdot w_i \phi_i(x)$$

- W tłumaczeniu na Reversi:
 - x to sytuacja na planszy, y to wartość sytuacji
 - $\phi_i(x)$ to pewien aspekt sytuacji na planszy, na przykład bilans punktów narożnych
 - w_i to waga tego parametru,
 - $f_w(x)$ to wartość funkcji heurystycznej dla planszy x
- Powyższa wartość pomnożona przez małe $\alpha > 0$, powinna zostać **odjęta** od aktualnej wartości w_i

Gradient dla funkcji liniowej

Wzór

Pochodna po w_i (dla liniowej funkcji f_w)

$$\frac{1}{|D_{\text{train}}|} \sum_{(x,y) \in D_{\text{train}}} 2 \cdot (f_w(x) - y) \cdot w_i \phi_i(x)$$

- W tłumaczeniu na Reversi:
 - x to sytuacja na planszy, y to wartość sytuacji
 - $\phi_i(x)$ to pewien aspekt sytuacji na planszy, na przykład bilans punktów narożnych
 - w_i to waga tego parametru,
 - $f_w(x)$ to wartość funkcji heurystycznej dla planszy x
- Powyższa wartość pomnożona przez małe $\alpha > 0$, powinna zostać **odjęta** od aktualnej wartości w_i
- Można to robić dla każdego składnika sumy osobno (to jest algorytm **SGD**)

Uwaga

Rozważaliśmy uczenie z nadzorem, czyli taki wariant, w którym dysponujemy dodatkowymi danymi (dotyczącymi np. prawidłowej klasyfikacji każdej próbki).

A co można zrobić, jeżeli mamy same próbki?

Uwaga

Rozważaliśmy uczenie z nadzorem, czyli taki wariant, w którym dysponujemy dodatkowymi danymi (dotyczącymi np. prawidłowej klasyfikacji każdej próbki).

A co można zrobić, jeżeli mamy same próbki?

1. Nauczyć się generować podobne próbki (**autokoder**).

Uwaga

Rozważaliśmy uczenie z nadzorem, czyli taki wariant, w którym dysponujemy dodatkowymi danymi (dotyczącymi np. prawidłowej klasyfikacji każdej próbki).

A co można zrobić, jeżeli mamy same próbki?

1. Nauczyć się generować podobne próbki (**autokoder**).
2. Pogrupować próbki (**algorytmy klasteryzacji**)

Uwaga

Rozważaliśmy uczenie z nadzorem, czyli taki wariant, w którym dysponujemy dodatkowymi danymi (dotyczącymi np. prawidłowej klasyfikacji każdej próbki).

A co można zrobić, jeżeli mamy same próbki?

1. Nauczyć się generować podobne próbki (**autokoder**).
2. Pogrupować próbki (**algorytmy klasteryzacji**)
3. Narysować próbki (**algorytmy wizualizacji**)

Uwaga

Rozważaliśmy uczenie z nadzorem, czyli taki wariant, w którym dysponujemy dodatkowymi danymi (dotyczącymi np. prawidłowej klasyfikacji każdej próbki).

A co można zrobić, jeżeli mamy same próbki?

1. Nauczyć się generować podobne próbki (**autokoder**).
2. Pogrupować próbki (**algorytmy klasteryzacji**)
3. Narysować próbki (**algorytmy wizualizacji**)
4. Znaleźć **dziwne** próbki (**algorytmy wykrywania nieprawidłowości**, czyli **anomaly detection**)

Uwaga

Rozważaliśmy uczenie z nadzorem, czyli taki wariant, w którym dysponujemy dodatkowymi danymi (dotyczącymi np. prawidłowej klasyfikacji każdej próbki).

A co można zrobić, jeżeli mamy same próbki?

1. Nauczyć się generować podobne próbki (**autokoder**).
2. Pogrupować próbki (**algorytmy klasteryzacji**)
3. Narysować próbki (**algorytmy wizualizacji**)
4. Znaleźć **dziwne** próbki (**algorytmy wykrywania nieprawidłowości**, czyli **anomaly detection**)

Z wizualizacją i autokoderami związana jest **redukcja wymiarowości**

Inne rodzaje uczenia

Uwaga

Rozważaliśmy uczenie z nadzorem, czyli taki wariant, w którym dysponujemy dodatkowymi danymi (dotyczącymi np. prawidłowej klasyfikacji każdej próbki).

A co można zrobić, jeżeli mamy same próbki?

1. Nauczyć się generować podobne próbki (**autokoder**).
2. Pogrupować próbki (**algorytmy klasteryzacji**)
3. Narysować próbki (**algorytmy wizualizacji**)
4. Znaleźć **dziwne** próbki (**algorytmy wykrywania nieprawidłowości**, czyli **anomaly detection**)


Z wizualizacją i autokoderami związana jest **redukcja wymiarowości**

Większość tych zagadnień dogłębnie omawiana jest na przedmiocie
Uczenie maszynowe

- Tworzymy zadanie uczenia się z nadzorem (funkcji identycznościowej)

Autokodery

- Tworzymy zadanie uczenia się z nadzorem (funkcji identycznościowej)
- Wariant jednowarstwowej funkcji liniowej jest skrajnie nieciekawy (bo?)
- Wielowarstwowa sieć, która ma część redukującą wymiar (coraz mniejsze warstwy) i analogiczną grupę warstw zwiększającą wymiar
- Może być użyteczna, bo tworzy wewnętrzną reprezentację obrazu



Bardziej skomplikowane autokodery (NVIDIA Celebrities)

Ci ludzie nie dadzą Ci autografu (przykładowe twarze dla losowej reprezentacji)

Bardziej skomplikowane autokodery (NVIDIA Celebrities)

Ci ludzie nie dadzą Ci autografu (przykładowe twarze dla losowej reprezentacji)



– pierwszy system generowanie twarzy o relatywnie dużej rozdzielczości źródło: <http://research.nvidia.com/>

O twarzach (2)

Oczywiście nie zawsze jest idealnie, bo:




źródło: <https://nerdist.com/nvidia-ai-headshots-fake-celebrities/>

Anomalie (1)

Autokoder może być użyty do wykrywania anomalii. Autokodery radzą sobie dobrze z **typowymi próbkami**.


Anomalie (1)

Autokoder może być użyty do wykrywania anomalii. Autokodery radzą sobie dobrze z **typowymi próbkami**.



Anomalie (1)

Autokoder może być użyty do wykrywania anomalii. Autokodery radzą sobie dobrze z **typowymi próbkami**.



Nietypowe próbki będą miały duży błąd rekonstrukcji!

Definicja

Klasteryzacja (grupowanie) to zadanie identyfikacji w próbce uczącej naturalnych grup związanych ze sobą obiektów.

Definicja

Klasteryzacja (grupowanie) to zadanie identyfikacji w próbce uczącej naturalnych grup związanych ze sobą obiektów.

Obiekt = wektor w $\mathcal{R}^n$

Definicja

Klasteryzacja (grupowanie) to zadanie identyfikacji w próbce uczącej naturalnych grup związanych ze sobą obiektów.

Obiekt = wektor w $\mathcal{R}^n$

- Najprostszy wariant: chcemy otrzymać konkretną liczbę grup, powiedzmy K
- Najprostszy algorytm: K-średnich (k-means)


Przez cały czas działania algorytmu pamiętamy K **prototypów**
(czyli punktów będących reprezentantami grupy)

Przez cały czas działania algorytmu pamiętamy K **prototypów** (czyli punktów będących reprezentantami grupy)


Algorytm przeplata dwie fazy:

1. Przypisanie każdego punktu do najbliższego mu prototypu
2. Obliczenie nowych prototypów jako **średnich** wszystkich punktów przypisanych do tego samego prototypu


Algorytm K-średnich. Przykład: $K=2$




Algorytm K-średnich. Przykład: $K=2$




Algorytm K-średnich. Przykład: $K=2$




Algorytm K-średnich. Przykład: $K=2$




Algorytm K-średnich. Przykład: $K=2$




Algorytm K-średnich. Przykład: $K=2$




K -średnich. Wybór reprezentatywnych pikseli, $K=5$




K -średnich. Wybór reprezentatywnych pikseli, $K=6$




K -średnich. Wybór reprezentatywnych pikseli, $K=7$




K -średnich. Wybór reprezentatywnych pikseli, $K=8$



K -średnich. Wybór reprezentatywnych pikseli, $K=12$



K -średnich. Wybór reprezentatywnych pikseli, $K=20$



K -średnich. Wybór reprezentatywnych pikseli, $K=100$

