

Sztuczna inteligencja. Ostatni wykład o różnych rzeczach

Paweł Rychlikowski

Instytut Informatyki UWr

24 czerwca 2026

- Zadania z więzami realizowane za pomocą logiki zdaniowej
Przykład: obrazki **logiczne**
- Algorytmy planowania (niestety pominiemy)
Przeszukiwanie specjalnej przestrzeni stanów, w której
dozwolone ruchy opisane są **formułami**

Obrazki logiczne jako CNF-SAT

Przykładowa reprezentacja

- Mamy zmienne (binarne) odpowiadające polom,
- Mamy zmienne typu: w wierszu 5 jest układ 00111001100

Co dalej?

Formuły

- W każdym wierszu (bądź kolumnie) jest jeden ze zgodnych ze specyfikacją układów (długa alternatywa)
- Formuły „tłumaczące” zmienne wierszowe na zmienne związane z polami:

$$W_{01101110} \rightarrow \neg X_0 \wedge X_1 \wedge X_2 \wedge \neg X_3 \wedge X_4 \wedge X_5 \wedge X_6$$

(to jest skrót dla n formuł typu $W_{01101110} \rightarrow L_i$)

Podstawowy brak: nie ma kwantyfikatorów, czyli pewne ogólne prawdy musimy wyrażać jako skończone alternatywy/koniunkcje.

Przykłady

- Każdy student jest pilny
- Pilni studenci zdają egzaminy, na które sa zapisani.
- Przynajmniej jedna osoba dostanie piątkę z AI

Przykłady

- $\forall x \text{Student}(x) \rightarrow \text{Pilny}(x)$
- $\forall x \forall e \text{Student}(x) \wedge \text{Pilny}(x) \wedge \text{Zapisany}(s, e) \rightarrow \text{Zdaje}(s, e)$
- (...)

Jeżeli mówimy o skończonej liczbie obiektów, możemy traktować kwantyfikatory jako skróty dla koniunkcji ($\forall$) lub alternatywy ($\exists$)

Definicja

Logika, w której możemy używać kwantyfikatorów dla zmiennych pierwszego rzędu po „zwykłych” elementach.

Przykłady były na poprzednim slajdzie

Kilka faktów o logice pierwszego rzędu

Twierdzenie 1

Logika pierwszego rzędu jest **nierozstrzygalna** (aczkolwiek istnieją pewne rozstrzygalne fragmenty)

- Nie ma nadziei na program, który będzie umiał dowieść każdego twierdzenia logiki 1-go rzędu w skończonym czasie
- Istnieją wszakże programy dowodzące twierdzenia, bazujące na różnych heurystykach, na przykład **Otter**, **Vampire**, **Prover9**, ...

Kilka faktów o logice pierwszego rzędu

Definicja

Fragment monadyczny logiki pierwszego rzędu to taki podzbiór tej logiki, w którym nie mamy funkcji (choć możemy mieć stałe), ani symboli relacyjnych o arności większej niż 1.

Przykład:

Studenci chodzący na Sztuczną Inteligencję są niegłupi!

$$\forall x(\text{Student}(x) \wedge \text{ChodziNaSI}(x) \rightarrow \text{NieGlupi}(x))$$

Twierdzenie 2

Fragment monadyczny logiki pierwszego rzędu jest rozstrzygalny (spełnialność jest **NEXPTIME-zupełna**).

Twierdzenie 3

Logika pierwszego rzędu z **dwiema zmiennymi** jest rozstrzygalna (spełnialność jest **NEXPTIME-zupełna**)

Twierdzenie 4

Logika pierwszego rzędu z **trzema zmiennymi** jest nierozstrzygalna

Uwaga

Różnych tego typu twierdzeń jest b. dużo. Różne formalizmy da się zredukować do logiki 1-go rzędu ograniczonej do jakiegoś konkretnego typu formuł.


Czy komputery umieją dowodzić rzeczywiście ciekawe twierdzenia?

- W szczególności takie, z którymi ludzie mają kłopoty?
- (za chwilę będzie odpowiedź)

Ale komputery potrafią sprawdzać dowody, asystować przy tworzeniu dowodów, sprawdzać przypadki, etc.

O pomarańczach

Jaki jest związek poniższego obrazka z **Wielką Matematyką**




Postulat Keplera (XVII w.)

Trójwymiarowe kule w trójwymiarowej przestrzeni najciaśniej da się umieścić, gdy ich środki tworzą na płaszczyznach przekroju sześciokąty.

O pomarańczach

Jaki jest związek poniższego obrazka z **Wielką Matematyką**



Twierdzenie Halesa (Thomas Hales, 2015)

Trójwymiarowe kule w trójwymiarowej przestrzeni najciaśniej da się umieścić, gdy ich środki tworzą na płaszczyznach przekroju sześciokąty.

O upakowaniu kul w przestrzeni

- Pierwsze doniesienia o dowodzie twierdzenia są z 1998
- Ogólna idea: **dowód na wyczerpanie** (możliwości lub czytelnika)
- Dowód rozpatruje tysiące przypadków i uzasadnia, że to są wszystkie alternatywy do rozpatrzenia.

O upakowaniu kul w przestrzeni


Ostatecznie dowód został **przepisany** do języka logiki i **zweryfikowany** przez systemy wspomagające dowodzenie twierdzeń.

Podobna jest historia z twierdzeniem o 4 barwach (że każdą mapę da się pokolorować czterema kolorami (żeby żadne kraje o niezerowej wspólnej granicy nie miały tego samego koloru):

- Dowód: 1976
- Formalna weryfikacja: 2004

Unit Distance Graphs

- Graf narysowany na płaszczyźnie
- Krawędzie mają długość 1



Hipoteza Erdősa (w przybliżeniu)

- Nie da się istotnie lepiej niż $O(N)$
- Obalona przez ChataGPT

Planar Point Sets with Many Unit Distances

OpenAI

Abstract

For a finite planar set P , let $\nu(P)$ be the number of unordered unit-distance pairs in P , and let $\nu(n)$ be the maximum of $\nu(P)$ over all n -point planar sets. We prove that, for some fixed $\delta > 0$, one has $\nu(n) \geq n^{1+\delta}$ for infinitely many n . This disproves the well-known unit distance conjecture from [Erd46].

The construction passes through an infinite unramified tower of totally real number fields with 3-power Galois groups of growing degree, in which a fixed set of rational primes splits completely. After adjoining i , these fields produce high-dimensional lattices with many elements whose images under every complex embedding have absolute value 1. Golod-Shafarevich theory ensures existence of an infinite such tower, even after a quotient step making the prescribed Frobenius classes trivial. A crucial property of the construction is that all resulting discriminants and class numbers are at most exponential in the extension degree.

Prompt.

Let $P \subset \mathbb{R}^2$ be a finite set of distinct points. Define

$$\nu(P) = \left| \left\{ \{p, q\} \in \binom{P}{2} : \|p - q\|_2 = 1 \right\} \right|$$

and, for each integer $n \geq 1$, $\nu(n) = \max_{\substack{P \subset \mathbb{R}^2 \\ |P|=n}} \nu(P)$.

Resolve Erdős's planar unit-distance problem completely: $\nu(n) \leq n^{1+O(1/\log \log n)}$ as $n \rightarrow \infty$? Equivalently, determine whether there exist absolute constants $C > 0$ and $N \in \mathbb{N}$ such that $\nu(n) \leq n^{1+C/\log \log n}$ for every integer $n \geq N$. Here $\log$ denotes the natural logarithm, and N may be taken large enough that $\log \log n > 0$. The hidden constant in $O(1/\log \log n)$ is absolute and independent of P and n .

A complete solution must prove exactly one of the following.

Affirmative resolution. Prove that there exist absolute constants $C > 0$ and $N \in \mathbb{N}$ such that every set $P \subset \mathbb{R}^2$ of $n \geq N$ distinct points satisfies $\nu(P) \leq n^{1+C/\log \log n}$.


Negative resolution. Prove that no such constants exist. Equivalently, prove that for every $C > 0$ and every $N \in \mathbb{N}$, there are an integer $n \geq N$ and a set $P \subset \mathbb{R}^2$ of n distinct points such that $\nu(P) > n^{1+C/\log \log n}$.

Pairs are unordered, the distance is the usual Euclidean distance in $\mathbb{R}^2$, and the asymptotic assertion is for all sufficiently large integers n , not merely infinitely many n .

Partial progress does not count unless it implies one of the two resolutions above. In particular, improved bounds such as $O(n^{4/3-\epsilon})$, better constants in the $n^{4/3}$ bound, finite verification, special cases, structural reductions, or heuristic evidence are insufficient unless they prove the full Erdős bound or disprove it.


- Nie znamy kosztu!
- W artykule wyjaśnienie dowodu na wiele stron
- Stała to: 6.24×10^{-32}
- Poprawiona przez amerykańskiego matematyka, Willa Sawina do 0.014

Sieci Bayesowskie (1)



- Mamy alarm przeciwwłamaniowy i dwoje sąsiadów Johna i Mary, którzy obiecali zadzwonić, jak alarm się włączy.
- Alarm uruchamia się również przy trzęsieniu ziemi (a mieszkamy na obszarze aktywnym sejsmicznie)
- **Problem:** Jakie jest prawdopodobieństwo włamania, jeżeli na przykład John zadzwonił, a Mary nie.

Sieci Bayesowskie. Liczba parametrów



- Powyższą sieć opisuje **10** parametrów
- Mamy 5 zmiennych, ich łączny rozkład „standardowo” opisujemy za pomocą $2^5 = 32$ parametrów (tak naprawdę 31)
- Zwięźlejszy opis łatwiej zapamiętać, łatwiej estymować parametry.

Definicja

Niech $(X_1, \dots, X_n)$ będą zmiennymi losowymi. **Siecią Bayesowską** (Bayesian network) nazwiemy DAG modelujący **wspólny rozkład prawdopodobieństwa** zmiennych X_i jako iloczyn **lokalnych prawdopodobieństw warunkowych** przypisanych do węzłów, określony wzorem:

$$P(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n P(x_i | x_{\text{Parents}(i)})$$

(skrót notacyjny: $P(X = x) = P(x)$)

Programy probabilistyczne

Definicja

Probabilistyczny program to program, który symuluje sieć bayesowską. Można go traktować jako inny zapis sieci.

Przykładowy program

```
# uwaga: trochę inny wariant niż na rysunku!
B = random.random() < p_burglary
E = random.random() < p_earthquake
A = B or E
if A:
    J = random.random() < pj_a
    M = random.random() < pm_a
else:
    J = random.random() < pj_not_a
    M = random.random() < pm_not_a
```

Proste wnioskowanie Bayesowskie

Zadajemy sieci pytania, na przykład: Jakie jest prawdopodobieństwo włamania, skoro dzwoni John, a nie dzwoni Mary?

Czyli pytamy o: $P(B = 1 | J = 1, M = 0)$? Jaki jest najprostszy (a zarazem uniwersalny) sposób na odpowiadanie na takie pytania?

Uwaga

Uniwersalny sposób to **próbkiwanie (sampling)**:

1. Generujemy dużo próbek (za pomocą zdefiniowanego przez sieć programu probabilistycznego)
2. Obliczamy stosunek (dla powyższego przykładu):

$$\frac{\text{liczba próbek z } (B, J, M) = (1, 1, 0)}{\text{liczba próbek z } (J, M) = (1, 0)}$$

Definicja

N-gramem nazywamy ciąg kolejnych elementów o długości N .
1-gramy to unigramy, 2-gramy to bigramy, 3-gramy to trigramy.

Za pomocą N-gramów tworzymy model języka, w którym staramy się przewidzieć kolejny element (o numerze N) na podstawie $N - 1$ elementów poprzednich.

Elementami mogą być litery, fonemy, słowa, sylaby, ...

Prawdopodobieństwo sekwencji liter dla języka

Prawdopodobieństwo sekwencji liter można obliczyć następująco:

$$P(a_1 \dots a_n) = P(a_1)P(a_2|a_1)P(a_3|a_1a_2) \dots P(a_n|a_1 \dots a_{n-1})$$

(gdzie a_i to litery, spacja, interpunkcja)

„Dalsze” prawdopodobieństwa szacujemy patrząc nie na całą historię, lecz na $N - 1$ liter poprzedzających znak przewidywany. Przykładowo dla $N = 2$ mamy

$$P(a_1 \dots a_n) \approx P(a_1)P(a_2|a_1)P(a_3|a_2)P(a_4|a_3) \dots P(a_n|a_{n-1})$$

Uwaga

Zauważmy, że dla zdania o długości K możemy stworzyć różne sieci Bayesowskie odpowiadające różnym sposobom modelowania tego zdania.

W takich sieciach zakładamy, że rozkłady w poszczególnych węzłach są takie same!

Definicja

Korpus jest to duży zbiór tekstów (czyli zbiór ciągów tokenów).

Przykładowo dla bigramów prawdopodobieństwa możemy szacować tak:

- $P(a_2|a_1) = \frac{P(a_1 a_2)}{P(a_1)}.$
- $P(a_1 a_2) = \frac{\text{cnt}(a_1 a_2)}{N-1}.$
- $P(a_1) = \frac{\text{cnt}(a_1)}{N}.$

Oczywiście przyjmujemy, że $N \approx N - 1$, co upraszcza wzory.

Generowanie pseudo tekstów w danym języku

Generator 3-gramowy

- Dla każdej pary znaków pamiętamy, jakich ma możliwych następników (i z jakim prawdopodobieństwem).
- Zaczynamy od wylosowania pary znaków (z tych, które mają następnika)
- Dla pary a_1a_2 losujemy następnika (a_3)
- Czynności powtarzamy dla pary a_2a_3 .

Uwaga

Taki generator jest **programem probabilistycznym** dla sieci Bayesowskiej opisującej zdanie (w wersji 3-gramowej).

- Zobaczymy, czy generowane w ten sposób teksty przypominają języki, z których czerpaliśmy rozkład.
- Tekst dla języka polskiego wyglądać może tak (model 4 gramowy):

-Curtki wiedzentów, Chińczy mał wzdługo skrętać w do Katorby z maszycję tań niemczajęto wscha pociąłem okoległoty, że mój przygodziwielsku. Zaczastępnego nigdy stonie mał mechała to się z naliśmy na kontru to nienia się zbyt dużej przebuję, że to zakładna eneś za pojego drzewu zbie zdołamięszczoraj ta

Zgadywanie (1)

-Antout demangue volla fois vous devient-là de la fait de fait viller ce inte que
je vra lors magis, vournie donne il travec que dispons trop de réussions sonné
au de toutera-t-il metitiques, il faire semblément d'adrontrique trop suivière u
ne né à consi dimauvaissé, heur nominus ce pours seul dit en ve

Odpowiedź

Tekst utworzony za pomocą modelu francuskiego

Zgadywanie (2)

Sydneš bývala v se, nejsem němí před se pracuji, každý musím třídil to, co mít
schodili jsem Green už všemusedla cigarelefon ve nám vzal jsme šokonců bezce poř
ádkakupile je v té vůbecky se zná učím neko pro noc mléčné poda nemoc byla sobil
a a to zábal názor, že se hlavír zpívala dneměl byl pokaždé tro

Odpowiedź

Tekst utworzony za pomocą modelu czeskiego

Zgadywanie (3)

```
Mae Warstift und andet unbedem keinigte Spaß gest ohnhof Mauert „sheraden letzte  
soll der das ein gehen Englied andessantischen spielerangenau, niemache stücks  
auf sich einflangs ist das Tom und ich nich sein ihreich ihm, das Dorf ich bitte  
n einsamtester sich wieden Aufgehört mich ein reppt; werdige is
```

Odpowiedź

Tekst utworzony za pomocą modelu niemieckiego

Zgadywanie (4)

e, pera adiarvar por factimadre el a ahora mieda que salumera de repo portuni6n
mi me lejos pluminalejorese de mor mundos y l6gica ir a mucho, y es qu6 hos ante
renz6 a un jab6licinal y des en contos, hizo las tenci6 mirar6n saber6as, usted
es los selversonito doro pa6s en aqu6 pue dar6 juegos o6r dema d

Odpowiedź

Tekst utworzony za pomoc6 modelu hiszpa6skiego.

(Ukryte) łańcuchy Markowa w innych zastosowaniach

- Generowanie muzyki (była jakaś nutka, albo kilka, jakie jest prawdopodobieństwo kolejnej)
- Opisywanie tekstu (czym jest konkretne wystąpienie słowa)
- Rozpoznawanie mowy (do niedawna abolutny lider, ciągle użyteczny)

Spacjowanie Pana Tadeusza

- Pamiętamy zadanie z pierwszej listy o wstawianiu spacji w sklejonym tekście.
- W rzeczywistości rozwiązywalibyśmy je trochę inaczej: korzystając z wiedzy o języku
- Wiedzę taką możemy nabyć analizując duże zbiory tekstów, tzw. **korpusy**.

Definicja

Model języka określa prawdopodobieństwo tego, że dany ciąg (słów, liter) jest poprawnym napisem języka.

Pozwala wybierać pomiędzy różnymi wariantami wypowiedzi (poprawy literówek, OCR, rozpoznawanie mowy, tłumaczenie)

- Najprostszy model języka to model **unigramowy**: rozważamy prawdopodobieństwo wystąpienia słów.
- Żeby zdecydować jak spacjować **partiachciała** sprawdzamy czy:

$$P(\text{partiach})P(\text{ciała}) > P(\text{partia})P(\text{chciała})$$

- Szacujemy:

$$P(\text{partiach}) \approx \frac{\text{ile razy słowo „partiach” było w korpusie}}{\text{liczba słów w korpusie}}$$

Problemy modelu unigramowego

- Preferuje długie wyrazy (no i ok?) – ew. można temu zaradzić biorąc średnią geometryczną prawdopodobieństwa
- Nie uwzględnia następst wyrazów.

Definicja

W **modelu bigramowym** zakładamy, że:

$$P(w_1 \dots w_n) = P(w_1|[start])P(w_2|w_1) \dots P(w_n|w_{n-1})$$

- Dynamiczny algorytm, wybierający sekwencję maksymalizującą prawdopodobieństwo w modelu bigramowym nazywa się **Algorytmem Viterbiego**
- Bardzo podobny do tego, jak rozwiązywaliśmy zadanie ze spacjowaniem.
- Drobna różnica:
 - a) w zadaniu z listy, wystarczyło pamiętać, jaki jest koszt (i kształt) optymalnej ścieżki kończącej się na danej literce.
 - b) tu musimy pamiętać te dane dla każdej literki i **każdego wyrazu, który może skończyć się w tym miejscu**

- Żeby je dokładnie omówić potrzeba innego przedmiotu
- (na przykład Modele językowe)

Podstawowa zasada

Model określa prawdopodobieństwo $P(w_t | w_1 \dots w_{t-1})$ – i tym samym daje możliwość generacji tekstów

Pytanie

Co możemy zrobić z modelem językowym danym jako *czarna skrzynka*?

- **PapuGaPT-2** jest przykładowym, nowoczesnym modelem językowym, do wczytania ze strony Hugging Face
- Generacja tekstów jest bardzo łatwa!
- Da się też obliczać prawdopodobieństwa tekstów (i na przykład wstawiać spacje tak, żeby maksymalizować prawdopodobieństwa)

```
from transformers import pipeline, set_seed
set_seed(42)
generator = pipeline('text-generation',
                     model='flax-community/papuGaPT2')
print (generator('I wtedy nagle')['generated_text'])
```

Lubię truskawki z

- bita śmietaną i syropami, jak i klasyczne truskawki z czekoladą, ale też z truskawkami, a
- cukrem. Są pyszne. Na ich bazie są takie lekkie jak budyń i w dodatku bezglutenowe.
- innymi owocami” są mi bliskie do tej pory, ale nie lubię tego określenia. To określenie
- konfiturą z borówki. Na blogu znajdziecie kilka przepisów z nimi w roli głównej. Dziś proponuję
- owocami, ale nie lubię ich zbyt wiele :) Pozdrawiam! Asiu - jeśli chodzi o owoce

Nie cierpię truskawek

- , a to ciasto jest obłędne. W środku jest w ogóle takie trochę, jakby to
- :) I to nie byle jakich - jagoda kamsimonella to moja ulubiona truskawkowa:) aha, bo
- ? O co chodzi? Na co? Czy moje dziecko może jeść truskawki? Czy musi jeść
- a one mi owocują już od kilku miesięcy. Teraz jak patrzę jaki napuchły, zmały tak
- z powodu tak złej pogody i kiepskiego zaopatrzenia rynku, więc nie miałam innego wyjścia, musiałam
- z truskawkami i z cukrem:) Tak naprawdę truskawki nie muszą być kwaśne! Na samą myśl

Pomnóż te dwie liczby, a następnie

- wpisz je w punktach na podstawie wzoru, który masz przed sobą. Powodzenia! Zestawienia te prezentują
- wpisz w odpowiednie miejsce liczby znajdujące się w polu powyżej, a w drugiej wpisz wynik
- wygraj pieniądze na naszym konkursie! Za pomocą myszki wysił się, by wybrać zwycięzcę i pomóc
- pomnóż je. Czy potrafisz, aby na koniec każdy z podanych wyników był dodatni? A jeśli
- podziel przez dwie cyfry. Niech suma obiegów będzie liczbą ujemną, zaś suma wszystkich par dodatnich

- Daniel Kahneman w swoich książkach (na przykład 'Pułapki myślenia. O myśleniu szybkim i wolnym' rozróżnia dwa 'podsystemy mózgu'
- **System 1**: heurystyczny, szybki, przydatny, ale skłonny do pewnego rodzaju błędów
- **System 2**: wolny, leniwy, analityczny, ...

Uwaga

Wydaje się, że to co powyżej widzieliśmy pasuje do Systemu 1 (w przeciwieństwie do większości wcześniejszych wykładów)

Ale czy na pewno?

Wszystko jest tekstem

Jako tekst możemy traktować:

- Zapis nutowy jakiego utworu
- Dowód twierdzenia w jakimś formalnym języku
- Program komputerowy
- Sekwencja stanów gry zręcznościowej albo stanów z Sokobana
- ...

GATO – A Generalist Agent



Figure 1 | **A generalist agent.** Gato can sense and act with different embodiments across a wide range of environments using a single neural network with the same set of weights. Gato was trained on 604 distinct tasks with varying modalities, observations and action specifications.

Connect4 i Shakespeare



2-22



- Modele językowe potrafią (?) grać w gry (choć są też wątpliwości)
- Trening:
 - wygeneruj rozgrywki (ciągi ruchów), traktuj je jako zdania w języka
 - wytrenuj model językowy

Connect4 i Shakespeare (2)

- Granie jako znajdowanie prawdopodobnych kontynuacji dla ciągu ruchów
- Sieć typu transformer (nanoGPT, ustawienia jak dla modelu Szekspira) można wytrenować, aby grała w Connect 4

Wynik

W pojedynkach ze swoim *mistrzem*, od którego uczyła się grać, wygrywa ponad 40% partii.

(na ten temat była już jedna praca magisterska, a pewnie powstanie więcej)